

Causal Step-Routing Distillation: Teaching Long-CoT Students Where to Look Back

Chưng cất định tuyến giữa các bước lập luận cho Long Chain-of-Thought

Đề xuất nghiên cứu (Research Proposal) — phiên bản 3.0

Nhóm nghiên cứu Long-CoT Distillation

[Tên thành viên, đơn vị, email]

26/09/2026

Tóm tắt nội dung

Chưng cất Long Chain-of-Thought (Long-CoT) từ mô hình lập luận lớn sang mô hình nhỏ hiện dựa chủ yếu vào hai cách: SFT trên trace của teacher, hoặc can thiệp vào tầng dữ liệu và trọng số loss. Các can thiệp đó gồm chọn trajectory, căn chỉnh prefix và che loss theo segment. Nhiều bằng chứng cho thấy student sao chép được *hình thức* của lập luận dài nhưng không sao chép được *chức năng* của nó. Đồng thời, cấu trúc giữa các bước quan trọng hơn nội dung từng bước.

Đề xuất này nhắm tới một thành phần cấu trúc cụ thể và đo được: *định tuyến giữa các bước*, tức mỗi bước sau đọc lại những bước nào. Thành phần này được hiện thực bởi các *receiver heads* ở tầng giữa và tầng muộn. Theo một phân tích lý thuyết gần đây, dưới giả định CoT-Markov, gradient của cross-entropy lên attention logits suy giảm hình học theo khoảng cách. Vì vậy, cross-entropy chỉ giám sát yếu các liên kết định tuyến ở xa.

Chúng tôi đề xuất **Causal Step-Routing Distillation (CSRD)**. CSRD chưng cất phân phối định tuyến *có hướng* giữa các bước, với các đặc điểm sau:

- phân phối được chuẩn hóa trên tập đích xa;
- phân phối được lấy trên receiver heads của teacher;
- target được kiểm chứng bằng can thiệp nhân quả (attention suppression);
- mọi đại lượng được định nghĩa trên span ký tự, nên không phụ thuộc tokenizer hay kích thước ẩn.

Một bổ đề đơn giản cho thấy tổng gradient của loss định tuyến lên các logit trở tới một bước đích bằng đúng độ lệch định tuyến, không phụ thuộc khoảng cách. Bổ đề cũng chỉ ra rằng cần một số hạng khớp khối lượng xa riêng.

Thiết lập thực nghiệm:

- **Cặp teacher-student:** Qwen3-8B (chế độ thinking) → Qwen3-1.7B-Base và Qwen3-4B-Base.
- **Dữ liệu:** 1.000 câu hỏi của s1K, trace do teacher sinh lại, dài tối đa 32k token.
- **Huấn luyện:** LoRA trên mọi lớp tuyến tính; full fine-tuning là phần mở rộng.
- **Đánh giá:** AIME24, AIME25, AMC12 và MATH500, đo bằng pass@1 và pass@3.
- **Baseline:** Segment-Level Selective SFT, SGL, P-ALIGN, RSR, và MoLSAKI (láng giềng gần nhất về cơ chế).
- **Kiểm định cơ chế:** QK-Restore, error injection theo khoảng cách, và một pilot 2 tuần với tiêu chí go/no-go định lượng.

Từ khóa: knowledge distillation, long chain-of-thought, attention routing, receiver heads, LoRA, mechanistic interpretability.

Mục lục

1	Giới thiệu	4
1.1	Câu hỏi nghiên cứu	4
1.2	Đóng góp dự kiến	5
2	Công trình liên quan	5
2.1	Long-CoT distillation ở tầng dữ liệu	5
2.2	Long-CoT distillation ở tầng loss: học có chọn lọc	6
2.3	On-policy distillation	6
2.4	Chưng cất ở tầng biểu diễn và attention	6
2.5	Phân tích cơ chế của mô hình lập luận	6
2.6	LoRA cho chưng cất lập luận	7
2.7	Định vị	7
3	Động cơ: bằng chứng và giả thuyết	7
3.1	E1 — Cấu trúc quan trọng hơn nội dung	7
3.2	E2 — Cơ chế định tuyến có thể định vị	8
3.3	E3 — Student học hình thức, không học chức năng	8
3.4	E4 — Cross-entropy giám sát định tuyến xa yếu	8
3.5	Phản chứng và giới hạn	9
3.6	Giả thuyết có thể bác bỏ	9
4	Phương pháp	9
4.1	Ký hiệu, phân đoạn và đồ thị bước	9
4.2	Định tuyến bước	10
4.3	Chọn receiver heads của teacher	10
4.4	Target nhân quả	11
4.5	Định tuyến của student và hàm mục tiêu	11
4.6	Phân tích gradient	11
4.7	Tham số hóa bằng LoRA	12
4.8	Tính toán hiệu quả	13
4.9	Các biến thể	13
5	Giao thức chẩn đoán	14
6	Thiết lập thực nghiệm	14
6.1	Mô hình	14
6.2	Dữ liệu	14
6.3	Huấn luyện	15
6.4	Đánh giá	16
6.5	Baseline	16
6.6	Ablation	17
6.7	Phân tích hành vi và cơ chế	17
7	Pilot và tiêu chí go/no-go	18
8	Rủi ro và giảm thiểu	18
9	Ngân sách tính toán	19
10	Kế hoạch thời gian	19

11 Kết quả kỳ vọng, hướng dự phòng và hạn chế	19
11.1 Kết quả kỳ vọng	19
11.2 Hướng dự phòng	19
11.3 Hạn chế	20
11.4 Đạo đức và giấy phép	20
A Bảng ký hiệu	23
B Phân đoạn và gán nhãn loại câu	23
C Giao thức error injection	24
D Checklist tái lập	24
E Danh mục cần kiểm tra thủ công trước khi chạy và nộp (nội bộ)	24

1 Giới thiệu

Các mô hình lập luận lớn như DeepSeek-R1 (DeepSeek-AI, 2025), QwQ (Qwen Team, 2025a) và Qwen3 (Qwen Team, 2025b) giải toán và lập trình bằng các chuỗi suy nghĩ dài 8k–32k token. Các chuỗi này chứa phản tư, quay lui và tự kiểm chứng. Chứng cất năng lực đó sang mô hình nhỏ (Hinton et al., 2015; Kim and Rush, 2016) đã trở thành thực hành tiêu chuẩn. Ví dụ, các mô hình DeepSeek-R1-Distill chỉ được SFT, không qua RL, trên khoảng 800k mẫu do DeepSeek-R1 tạo ra (DeepSeek-AI, 2025).

Nghiên cứu năm 2025–2026 về Long-CoT distillation tập trung vào hai hướng:

- (i) *Dữ liệu*: chọn trajectory phù hợp với student (Yang et al., 2026; MI-Distillation, 2026; LARK, 2026), căn chỉnh prefix (Liu et al., 2026), và sinh dữ liệu có sự hợp tác giữa teacher và student (TESSY, 2026).
- (ii) *Trọng số loss*: che loss ở các segment hoặc bước ít giá trị, dựa trên attribution (Wang et al., 2026) hoặc hình học gradient (Fan et al., 2026).

Cả hai hướng đều dùng tín hiệu (kể cả tín hiệu nội tại) để quyết định *học cái gì*. Mục tiêu học thì vẫn là token của teacher.

Khoảng cách giữa hình thức và chức năng. Nhiều nghiên cứu độc lập cho thấy student học được bề mặt của lập luận dài mà không học được chức năng của nó:

- Mô hình nhỏ khó hưởng lợi từ Long-CoT của teacher mạnh (Li et al., 2025b).
- Với khoảng 8k mẫu Long-CoT, mô hình nhỏ có thể mất tới 75% hiệu năng ban đầu (Luo et al., 2025).
- Phản tư của mô hình lập luận chủ yếu mang tính xác nhận (Kang et al., 2025).
- Student không tái tạo được cách teacher phân bổ tính toán theo độ khó (Hu et al., 2026).
- Chứng cất CoT có thể làm student *kém hơn* chính nó trước khi chứng cất (Kajitsuka et al., 2026).

Trong khi đó, yếu tố quyết định việc học Long-CoT là *cấu trúc* chứ không phải nội dung từng bước: xáo trộn thứ tự các bước gây hại nhiều hơn làm sai nội dung (Li et al., 2025a).

Ý tưởng chính. Chúng tôi xác định một thành phần cấu trúc cụ thể, gọi là *định tuyến giữa các bước*: khi sinh bước i , mô hình dồn attention vào những bước $j < i$ nào. Thành phần này có ba đặc điểm:

- (a) Nó được hiện thực bởi một nhóm nhỏ receiver heads có thể định vị (Bogdan et al., 2025).
- (b) Theo phân tích gradient-locality (Zhou et al., 2026), cross-entropy dạy nó yếu khi khoảng cách lớn.
- (c) Nó định nghĩa được ở mức bước, nên so sánh được giữa teacher và student bất kể tokenizer.

CSRD chứng cất trực tiếp thành phần này. Tín hiệu nội tại được dùng làm *target* học, không chỉ làm bộ lọc chọn dữ liệu.

1.1 Câu hỏi nghiên cứu

- RQ1** Sau SFT trên Long-CoT, student có lệch định tuyến giữa các bước so với teacher không? Độ lệch có tăng theo khoảng cách và tập trung ở các câu neo không?
- RQ2** Độ lệch định tuyến có dự báo lỗi của student, sau khi đã kiểm soát độ dài và perplexity, hay không?
- RQ3** CSRD có thu hẹp độ lệch và cải thiện accuracy, khả năng phát hiện lỗi và khả năng tổng quát hóa so với các phương pháp Long-CoT distillation mạnh nhất không? Phần cải thiện có thực sự đến từ tham số định tuyến (W_Q, W_K) không?
- RQ4** Lợi ích có giữ được khi thay đổi quy mô student (1.7B, 4B), quy mô teacher (Qwen3-8B, Qwen3-32B), và khi chuyển từ LoRA sang full fine-tuning không?

1.2 Đóng góp dự kiến

- C1. Chẩn đoán.** Một giao thức đo *routing gap* theo khoảng cách, theo loại câu và theo khả năng dự báo lỗi, kèm kiểm định nhân quả QK-Restore.
- C2. Phương pháp.** CSRD: chứng cất định tuyến có hướng, chuẩn hóa trên tập đích xa, lấy trên receiver heads, có target nhân quả, không phụ thuộc tokenizer. Phương pháp được tham số hóa hiệu quả bằng LoRA, gồm một biến thể adapter Q/K riêng để tách riêng tác động định tuyến.
- C3. Phân tích.** Một bộ đề về gradient của loss định tuyến, đặt đối chiếu với tính cục bộ của gradient cross-entropy. Bộ đề cũng cho hệ quả thiết kế: số hạng khớp khối lượng xa là bắt buộc.
- C4. Đánh giá.** So sánh công bằng với các baseline Long-CoT distillation đương đại: cùng dữ liệu s1K, cùng cấu hình LoRA, cùng ngân sách tinh chỉnh, đo pass@1 và pass@3 bằng ước lượng không chệch. Kèm theo là các phép thử hành vi: error injection theo khoảng cách, anchor deletion và phản tư có tác dụng.

Theo khảo sát của chúng tôi đến 09/2026, chưa có công trình nào chứng cất định tuyến bước→bước từ teacher Long-CoT. Đây là kết quả tìm kiếm âm tính và sẽ được quét lại trước khi nộp bài.

Cấu trúc tài liệu. Mục 2 tổng quan công trình liên quan. Mục 3 trình bày bằng chứng và giả thuyết. Mục 4 mô tả CSRD. Mục 5 định nghĩa giao thức chẩn đoán. Mục 6 trình bày thiết lập thực nghiệm. Mục 7–10 gồm pilot, rủi ro, ngân sách và lịch. Mục 11 bàn về kết quả kỳ vọng và hạn chế.

2 Công trình liên quan

2.1 Long-CoT distillation ở tầng dữ liệu

Chọn và tổ chức dữ liệu theo student. Mix Distillation trộn CoT dài và ngắn cho mô hình $\leq 3B$ (Li et al., 2025b). Tuy nhiên, Kajitsuka et al. (2026) chỉ ra rằng hiệu quả biểu kiến của chiến lược này phần lớn đến từ chênh lệch siêu tham số làm giảm số bước cập nhật (Appendix B của bài). Các nghiên cứu khác:

- Rank-Surprisal Ratio (RSR) chọn trajectory theo mức “informative alignment”. Trên 11 teacher và 5 student, RSR đạt tương quan Spearman trung bình 0.86 với hiệu năng sau huấn luyện (Yang et al., 2026). LARK chọn trajectory theo khả năng học được, với RSR là baseline (LARK, 2026).
- MI-Distillation tạo một phổ teacher bằng cách nội suy trọng số giữa QwQ-32B và Qwen2.5-32B-Instruct, rồi chọn trajectory theo surprisal (MI-Distillation, 2026).
- DASD chỉ ra ba hạn chế của sequence-level KD: phủ phân phối kém, lệch với năng lực student, và exposure bias (Yan et al., 2026).
- TESSY để teacher sinh token “năng lực” còn student sinh token “phong cách”. Với GPT-OSS-120B→Qwen3-8B, SFT thuần trên dữ liệu teacher làm giảm 3.25% trên LiveCodeBench-Pro, trong khi TESSY tăng 11.25% (TESSY, 2026).
- Merge-of-Thought xen kẽ SFT theo từng teacher với việc hợp nhất trọng số (MoT, 2025). CoRD dùng nhiều teacher cùng giải mã từng bước (CoRD, 2026).

Căn chỉnh prefix. P-ALIGN tìm prefix tối thiểu đủ dùng của trace teacher bằng cách cho student tự đánh giá kết hợp tìm kiếm nhị phân, rồi để student sinh phần tiếp theo. Với trace DeepSeek-R1 từ s1K-1.1 và huấn luyện LoRA, phương pháp cải thiện Pass@1 trung bình 3.69 điểm (Qwen2.5-7B-Instruct) và 2.80 điểm (Qwen3-8B) so với Long-CoT SFT (Liu et al., 2026). UPFT chỉ học một số token đầu của lời giải (Ji et al., 2025).

2.2 Long-CoT distillation ở tầng loss: học có chọn lọc

Ý tưởng học có chọn lọc bắt nguồn từ Rho-1, một phương pháp chỉ huấn luyện trên các token hữu ích (Lin et al., 2024). Với Long-CoT:

- **Segment-Level Selective SFT** (Wang et al., 2026) (ICLR 2026) dùng Integrated Gradients để đo đóng góp của từng segment vào đáp án đúng. Phương pháp giữ các segment có attribution mạnh và nhất quán vừa phải, và che loss ở các segment còn lại. Cài đặt gốc: full fine-tuning trên LIMO (817 mẫu), độ dài tối đa 16,384 token. Kết quả: accuracy tăng tới 4.7% (tương đối), đầu ra ngắn đi tới 18%. Ablation của bài cho thấy *che loss* tốt hơn *cắt bỏ* segment.
- **SGL** (Fan et al., 2026) phân tích phổ (SVD) của gradient theo từng bước và che loss ở các bước nằm ngoài “consensus subspace”. Thông tin chi tiết hiện chỉ có từ nguồn thứ cấp và một bản cài đặt không chính thức; xem Mục 6.5.
- Skip-Thinking chứng cất theo chunk (Skip-Thinking, 2025). TokenSkip nén CoT ở mức token (Xia et al., 2025). BRIDGE kết hợp che loss theo cấu trúc với GRPO (Structure-aware masking, 2026).

Các phương pháp nhóm này dùng tín hiệu nội tại (attribution, gradient) để *chọn* phần cần học. CSRD khác ở chỗ lấy một tín hiệu nội tại (định tuyến attention) làm *target* để học.

2.3 On-policy distillation

On-policy distillation (OPD) huấn luyện student trên rollout của chính nó với phản hồi từ teacher (Agarwal et al., 2024; Gu et al., 2024; OPD Survey, 2026). Với chuỗi dài, các hướng nghiên cứu gồm:

- chứng cất chỉ trên prefix của rollout (Prefix OPD, 2026);
- hiện tượng suy giảm khả năng dạy cục bộ ở phần sau của trajectory (Prefix Teach, 2026);
- OPD không phụ thuộc tokenizer (SimpleOPD, 2026);
- OPD dựa trên các token hỗ trợ quyết định (Finding the Evidence, 2026).

OPD tốn nhiều compute cho rollout. Chúng tôi xem nó là hướng mở rộng, trực giao với CSRD.

2.4 Chứng cất ở tầng biểu diễn và attention

Các phương pháp kinh điển gồm FitNets (Romero et al., 2015), TinyBERT (Jiao et al., 2020), MiniLM/MiniLMv2 (Wang et al., 2020, 2021), RKD (Park et al., 2019) và các phương pháp dựa trên CKA (Kornblith et al., 2019). Chúng khớp hidden state, attention hoặc quan hệ đối xứng ở mức token hay mẫu. Chúng không có khái niệm bước lặp luận và chưa được áp dụng cho chuỗi 8k–32k token.

Gần hơn với chúng tôi:

- **MoLSAKI** (Chen et al., 2025) chứng cất attention từ từng bước (tách theo câu) tới các *token số* then chốt, kết hợp Mixture-of-Layers. Bài tự nhận là phương pháp đầu tiên dùng stepwise attention trong CoT distillation, và hoạt động được giữa các tokenizer khác nhau nhờ gộp lên mức bước–từ. Tuy vậy, thực nghiệm giới hạn ở CoT ngắn.
- MTA căn chỉnh hình học quan hệ *đối xứng* giữa các span cú pháp theo độ sâu, cho bài toán instruction-following (Pham et al., 2026).
- LoRi (LoRi, 2026) và KaVa (Kuzina et al., 2026) chứng cất quỹ đạo biểu diễn hoặc KV-cache cho latent reasoning.

2.5 Phân tích cơ chế của mô hình lặp luận

- **Thought Anchors** (Bogdan et al., 2025) tìm các *receiver heads* dựa trên kurtosis của “vertical attention score”. Điểm này chỉ lấy trung bình trên các cặp câu cách nhau ít nhất 4 câu.

Bảng 1: Định vị CSRD. ✓: có; ✗: không; ○: một phần; -: không áp dụng. “Target nội tại”: tín hiệu nội tại của teacher được dùng làm mục tiêu học, không chỉ để chọn dữ liệu hay trọng số.

Phương pháp	Loại can thiệp	Long-CoT	Đơn vị bước	Target nội tại	Định tuyến bước→bước	Không phụ thuộc tokenizer
RSR (Yang et al., 2026)	Chọn trajectory	✓	✗	✗	✗	–
P-ALIGN (Liu et al., 2026)	Căn chỉnh prefix	✓	✗	✗	✗	–
TESSY (TESSY, 2026)	Sinh dữ liệu hợp tác	✓	○	✗	✗	–
Segment Selective SFT (Wang et al., 2026)	Che loss (IG)	✓	✓	✗	✗	–
SGL (Fan et al., 2026)	Che loss (phổ gradient)	✓	✓	✗	✗	–
TinyBERT / MiniLM (Jiao et al., 2020; Wang et al., 2021)	KD attention token	✗	✗	✓	✗	✗
MoLSAKI (Chen et al., 2025)	KD attention bước→token	✗	✓	✓	○	✓
Hiding in Plain Sight (Hiding in Plain Sight, 2026)	Chống chưng cất	✓	✓	✗	✗	–
CSRD (đề xuất)	KD định tuyến	✓	✓	✓	✓	✓

- **Hiding in Plain Sight** (Hiding in Plain Sight, 2026) dùng receiver heads (trừ đi hồ sơ trung bình của các head, chọn theo excess kurtosis) để định vị các câu neo, rồi nhiễu các câu này nhằm *chống* chưng cất. Đây là công trình duy nhất chúng tôi thấy nối receiver heads với khả năng bị chưng cất.
- **Thinking Sparks** (Park et al., 2025): distillation và SFT làm xuất hiện dần các attention head lập luận ổn định.
- **Attention Amnesia** (Zhou et al., 2026) chứng minh gradient CE lên attention logits suy giảm hình học theo khoảng cách và tách được thành thành phần định tuyến và thành phần trích xuất. Bài cũng cho thấy khôi phục W_Q, W_K về trước SFT (QK-Restore) lấy lại khả năng truy hồi xa ở mô hình hybrid mà vẫn giữ năng lực lập luận.

2.6 LoRA cho chưng cất lập luận

- Với Qwen2.5-32B-Instruct, LoRA rank 64 (cập nhật dưới 5% tham số, learning rate 10^{-4} so với 10^{-5} của full FT) đạt kết quả tương đương SFT đầy đủ trên 17k mẫu Long-CoT (Li et al., 2025a).
- LoRA khớp full FT khi áp lên *mọi* ma trận, nhất là MLP; LoRA chỉ trên attention kém hơn ngay cả khi cùng số tham số; learning rate tối ưu khoảng $10\times$ so với full FT; và LoRA kém chịu batch lớn hơn (Schulman and Thinking Machines Lab, 2025).
- LoRA “học ít hơn và quên ít hơn” (Biderman et al., 2024).

2.7 Định vị

Bảng 1 so sánh CSRD với các công trình gần nhất.

3 Động cơ: bằng chứng và giả thuyết

3.1 E1 — Cấu trúc quan trọng hơn nội dung

Li et al. (2025a) fine-tune Qwen2.5-32B-Instruct với 17k mẫu Long-CoT và đạt 56.7% trên AIME 2024, tăng 40.0 điểm. Các thí nghiệm nhiều có kiểm soát cho thấy:

- huấn luyện trên mẫu có đáp án sai chỉ kém 3.2%;

- bỏ từ khóa phản tư ít ảnh hưởng;
- xáo trộn 67% số bước làm AIME 2024 giảm 13.3 điểm.

Tín hiệu học tập vì vậy nằm ở *quan hệ giữa các bước*.

3.2 E2 — Cơ chế định tuyến có thể định vị

Theo [Bogdan et al. \(2025\)](#):

- Receiver heads dồn attention vào một số ít câu được mọi câu phía sau đọc lại.
- Receiver heads phổ biến hơn ở các tầng muộn.
- Điểm kurtosis theo head có độ tin cậy split-half cao ($r = .67$).
- Các câu neo chủ yếu là câu lập kế hoạch và quản lý bất định.
- Mô hình lập luận (R1-Distill-Qwen-14B) dồn attention vào các câu có receiver score cao mạnh hơn base model tương ứng.

[Hiding in Plain Sight \(2026\)](#) dùng chính các head này để định vị câu neo và nhiễu chúng nhằm cản trở chứng cất. Điều đó gợi ý *gián tiếp* rằng các câu neo mang giá trị chứng cất.

3.3 E3 — Student học hình thức, không học chức năng

- Mô hình $\leq 3B$ khó hưởng lợi từ Long-CoT của teacher mạnh ([Li et al., 2025b](#)).
- Với khoảng 8k mẫu Long-CoT, mô hình nhỏ có thể mất tới 75% hiệu năng ban đầu. Hiện tượng suy giảm cũng xuất hiện ở Qwen2.5-14B (từ 50% xuống 45%) ([Luo et al., 2025](#)).
- Phản tư của mô hình lập luận chủ yếu mang tính xác nhận ([Kang et al., 2025](#)).
- Trên 14 mô hình, tương quan giữa chi phí suy luận của mô hình và thời gian phản ứng của con người là $\bar{r} = 0.64$ ở teacher nhưng chỉ $\bar{r} = 0.34$ ở student. Các tác giả gọi hiện tượng này là “sụp đổ căn chỉnh chức năng” ([Hu et al., 2026](#)).

3.4 E4 — Cross-entropy giám sát định tuyến xa yếu

Với $e_{tu} = \langle q_t, k_u \rangle / \sqrt{d_h}$ và $A_{tu} = \text{softmax}_u(e_{tu})$,

$$\frac{\partial \mathcal{L}_{CE}}{\partial e_{tu}} = A_{tu} G_t^\top (v_u - \bar{v}_t), \quad G_t = \frac{\partial \mathcal{L}_{CE}}{\partial o_t}, \quad \bar{v}_t = \sum_{u'} A_{tu'} v_{u'}. \quad (1)$$

Dưới giả định CoT-Markov, [Zhou et al. \(2026\)](#) chứng minh kỳ vọng độ lớn gradient này suy giảm hình học theo khoảng cách $\tau = t - u$. Họ cũng chứng minh gradient có thể tách thành thành phần định tuyến và thành phần trích xuất. Thực nghiệm cho thấy CoT-SFT làm W_Q, W_K trôi về phía mẫu hình cục bộ. Ví dụ, HypeNet-9B trên NIAH-Single-2@256K giảm từ 67.2% xuống 9.4%.

3.5 Phản chứng và giới hạn

Ba điểm yếu phải xử lý trực tiếp

1. **Attention không đồng nghĩa với nhân quả.** Một bản tái hiện Thought Anchors thấy trọng số attention chỉ tương quan yếu với mức quan trọng nhân quả. Phụ thuộc cục bộ chiếm ưu thế, và nhiều phụ thuộc xa có thể chỉ là hệ quả của trùng lặp token (LessWrong, 2025); xem thêm Jain and Wallace (2019); Wiegrefe and Pinter (2019). $\Rightarrow$ CSRD dùng target nhân quả và chọn head theo nhân quả (Mục 4.4).
2. **E4 được chứng minh mạnh nhất trên mô hình hybrid linear-attention.** Với Transformer thuần softmax, bằng chứng không đồng nhất. Qwen2.5-3B có đường suy giảm gradient với đuôi gần như phẳng. Ngược lại, Mistral-7B có NIAH-Single-3@64K giảm từ 81.0 xuống 4.8 sau SFT (Zhou et al., 2026). $\Rightarrow$ Phải đo trực tiếp trên student (pilot, Mục 7).
3. **QK-Restore giữ được năng lực lập luận ở mô hình hybrid (Zhou et al., 2026).** Nếu điều tương tự xảy ra ở student của chúng tôi, những thay đổi định tuyến do SFT tạo ra có thể không cần cho lập luận. $\Rightarrow$ Kiểm định D6 (Mục 5) và phân tích QK-Restore trên mô hình CSRD (Mục 6.7).

3.6 Giả thuyết có thể bác bỏ

Giả thuyết 1 (Routing gap tăng theo khoảng cách). Với student sau SFT, routing gap $RG(b)$ (Định nghĩa 2) tăng theo bin khoảng cách b . *Bác bỏ nếu* độ dốc theo log khoảng cách có khoảng tin cậy 95% (bootstrap) chứa 0, hoặc $RG(\geq 64)/RG([4, 8]) < 1.2$.

Giả thuyết 2 (Tập trung ở câu neo). Routing gap trên các hàng hoặc đích là câu neo lớn hơn trên câu tính toán. *Bác bỏ nếu* kiểm định hoán vị có ghép cặp không có ý nghĩa ở mức 0.05.

Giả thuyết 3 (Dự báo lỗi). Routing gap bổ sung khả năng dự báo lỗi giải sai vượt các biến kiểm soát (độ dài, NLL, số dấu hiệu phản tư). *Bác bỏ nếu* phần AUC tăng thêm < 0.03 .

Giả thuyết 4 (Can thiệp). CSRD đạt đồng thời ba điều: (i) giảm $RG(\geq 32)$ ít nhất 30% và tăng pass@1 trung bình trên bốn benchmark ít nhất 1.5 điểm so với SFT cùng cấu hình; (ii) không kém baseline Long-CoT mạnh nhất trong số Segment Selective SFT, SGL và P-ALIGN; (iii) phần lợi ích so với SFT giảm ít nhất một nửa khi tắt LoRA trên W_Q, W_K (QK-Restore). *Bác bỏ nếu* không đạt (i) và (ii) trên cả hai student (1.7B và 4B).

Giả thuyết 5 (Tổng quát hóa). Lợi ích giữ được khi teacher lớn hơn (Qwen3-32B) và dưới full fine-tuning.

4 Phương pháp


Hình 1 tóm tắt quy trình. Teacher được chạy *một lần* ở chế độ offline để trích target định tuyến. Student được huấn luyện bằng LoRA với $\mathcal{L}_{CE}$ cộng các loss định tuyến. Các loss này chỉ được tính trên một số ít head và tầng, thông qua lấy mẫu truy vấn.

4.1 Ký hiệu, phân đoạn và đồ thị bước

Mỗi mẫu gồm câu hỏi q , phần suy nghĩ và lời giải cuối a . Phần suy nghĩ được phân đoạn thành các bước $s_1, \dots, s_n$. Tập nút là $\mathcal{V} = \{v_0=q, v_1=s_1, \dots, v_n=s_n, v_{n+1}=a\}$; mỗi nút là một khoảng ký tự $[\beta_k, \varepsilon_k)$.

Phân đoạn. Mặc định:

1. Tách theo $\backslash n \backslash n$. Lựa chọn này phù hợp với quan sát rằng các từ khóa phản tư như “wait” thường xuất hiện ngay sau $\backslash n \backslash n$ (Yang et al., 2025).
2. Gộp các đoạn ngắn hơn 40 ký tự vào đoạn trước.



Hình 1: Tổng quan CSRD. Nét đứt: các span ký tự được ánh xạ sang token của từng mô hình, nên teacher và student có cùng tập nút ngay cả khi khác tokenizer.

3. Nếu $n > 400$, gộp dần cặp bước liền kề gần nhất cho tới khi $n \leq 400$.

Ablation (A9) so sánh bốn cách phân đoạn: theo câu (như Thought Anchors), theo \n\n, theo episode mở đầu bằng từ khóa (như Wang et al., 2026), và theo chunk gồm 3 bước.

Ánh xạ sang token. Với mô hình $M \in \{T, S\}$,

$$\mathcal{I}_M(v_k) = \{t : \text{ký tự đầu của token } t \in [\beta_k, \varepsilon_k)\},$$

lấy từ offset mapping của tokenizer. Vì các nút được định nghĩa trên ký tự, teacher và student luôn có cùng n nút.

4.2 Định tuyến bước

Định nghĩa 1 (Định tuyến theo truy vấn và theo hàng). Xét tầng l , head h và token truy vấn $t \in \mathcal{I}_M(v_i)$. Khối lượng attention của t lên nút $j < i$ là $m_t^{(l,h)}(j) = \sum_{u \in \mathcal{I}_M(v_j)} A_{t,u}^{(l,h)}$. Với ngưỡng $d_{\min}$, tập đích xa của bước i là $\mathcal{F}(i) = \{0\} \cup \{j : 1 \leq j \leq i - d_{\min}\}$. Định nghĩa

$$Z_t^{(l,h)} = \sum_{j \in \mathcal{F}(i)} m_t^{(l,h)}(j), \quad \tilde{R}_t^{(l,h)}(j) = \frac{m_t^{(l,h)}(j)}{Z_t^{(l,h)}}, \quad j \in \mathcal{F}(i). \quad (2)$$

Định tuyến theo hàng là trung bình trên tập truy vấn $\mathcal{Q}_M(i)$:

$$\tilde{R}_M^{(l,h)}[i, \cdot] = \frac{1}{|\mathcal{Q}_M(i)|} \sum_{t \in \mathcal{Q}_M(i)} \tilde{R}_t^{(l,h)}, \quad Z_M^{(l,h)}[i] = \frac{1}{|\mathcal{Q}_M(i)|} \sum_{t \in \mathcal{Q}_M(i)} Z_t^{(l,h)}.$$

Chỉ các hàng có $|\mathcal{F}(i)| \geq 2$ tham gia vào loss.

Chuẩn hóa *theo từng truy vấn trước*, rồi mới lấy trung bình, là lựa chọn có chủ đích: Bổ đề 1 áp dụng chính xác cho từng truy vấn. Mặc định $d_{\min} = 4$ bước. Bogdan et al. (2025) dùng ngưỡng 4 câu; vì mỗi bước của chúng tôi là một đoạn, ngưỡng tương ứng xa hơn, và ablation A1 quét $d_{\min} \in \{1, 2, 4, 8\}$.

4.3 Chọn receiver heads của teacher

Vertical score của nút j tại head (l, h) là $\nu_j^{(l,h)} = \mathbb{E}_{i: i-j \geq d_{\min}} [\tilde{R}_T^{(l,h)}[i, j]]$. Chúng tôi xét hai điểm receiver:

- (a) **Kurtosis thô** (Bogdan et al., 2025): $\kappa^{(l,h)} = \mathbb{E}_{\mathcal{D}_{\text{cal}}} [\text{Kurt}_j(\nu_j^{(l,h)})]$.

- (b) **Excess kurtosis sau khi trừ nền** (mặc định), theo [Hiding in Plain Sight \(2026\)](#): trừ hồ sơ vertical trung bình trên mọi head, $\hat{\nu}_j^{(l,h)} = \nu_j^{(l,h)} - \frac{1}{|\mathcal{H}|} \sum_{(l',h')} \nu_j^{(l',h')}$, rồi tính excess kurtosis của $\{\hat{\nu}_j\}$. Cách này loại bỏ các mẫu hình chung như attention sink.

Các tầng được chia thành hai band độ sâu, $\mathcal{B}_1 = [0.4, 0.7]$ và $\mathcal{B}_2 = [0.7, 1.0]$. Trong mỗi band, chọn top- $K_T = 16$ head, tổng cộng 32 head; con số này gần với $K = 28$ trong [Hiding in Plain Sight \(2026\)](#). Tập hiệu chỉnh $\mathcal{D}_{\text{cal}}$ gồm 200 trace. Chúng tôi báo cáo độ ổn định split-half của lựa chọn.

Target định tuyến. $P_i^{(b)} = \frac{1}{|\mathcal{H}_T^{(b)}|} \sum_{(l,h) \in \mathcal{H}_T^{(b)}} \tilde{R}_T^{(l,h)}[i, \cdot]$ và $Z_{T,i}^{(b)} = \frac{1}{|\mathcal{H}_T^{(b)}|} \sum_{(l,h) \in \mathcal{H}_T^{(b)}} Z_T^{(l,h)}[i]$. Với teacher, tập truy vấn là toàn bộ $\mathcal{Q}_T(i) = \mathcal{I}_T(v_i)$.

4.4 Target nhân quả

Trên một tập con $\mathcal{D}_c$ (khoảng 5% số trace), ta dùng attention suppression ([Bogdan et al., 2025](#)). Với một nút đích j , chặn attention từ mọi vị trí phía sau tới các token thuộc $\mathcal{I}_T(v_j)$ ở mọi tầng, rồi đo

$$C[i, j] = \frac{1}{|\mathcal{I}_T(v_i)|} \sum_{t \in \mathcal{I}_T(v_i)} \text{KL}(p_T(\cdot | x_{<t}) \| p_T^{-j}(\cdot | x_{<t})). \quad (3)$$

Một lượt forward có chặn j cho ra $C[\cdot, j]$ với mọi $i > j$. Vì vậy chi phí là $|J|$ lượt forward cho mỗi trace, với J là tập top-24 nút theo vertical score. Chuẩn hóa theo hàng trên $\mathcal{F}(i) \cap J$ ta được $\tilde{C}_i$. Target nhân quả phục vụ ba mục đích:

- (i) báo cáo tương quan Spearman giữa P_i và $\tilde{C}_i$;
- (ii) chọn head theo nhân quả (biến thể CSRD-C);
- (iii) làm loss phụ $\mathcal{L}_{\text{causal}}$.

4.5 Định tuyến của student và hàm mục tiêu

Trong mỗi band, tập head của student $\mathcal{H}_S^{(b)}$ được chọn sau giai đoạn warmup chỉ dùng CE: lấy top- $K_S = 16$ theo cùng điểm receiver và giữ cố định sau đó. Ablation A5 so sánh với trung bình toàn band và với trọng số head học được. Định tuyến của student là $Q_i^{(b)} = \frac{1}{|\mathcal{H}_S^{(b)}|} \sum_{(l,h) \in \mathcal{H}_S^{(b)}} \tilde{R}_S^{(l,h)}[i, \cdot]$, và tương tự cho $Z_{S,i}^{(b)}$. Hàm mục tiêu:

$$\mathcal{L}_{\text{route}} = \sum_b \frac{1}{\sum_i w_i} \sum_i w_i \text{KL}(P_i^{(b)} \| Q_i^{(b)}), \quad (4)$$

$$\mathcal{L}_{\text{mass}} = \sum_b \frac{1}{\sum_i w_i} \sum_i w_i \text{KL}(\text{Ber}(Z_{T,i}^{(b)}) \| \text{Ber}(Z_{S,i}^{(b)})), \quad (5)$$

$$\mathcal{L}_{\text{causal}} = \mathbb{E}[x \in \mathcal{D}_c] \sum_b \frac{1}{|\text{rows}|} \sum_i \text{KL}(\tilde{C}_i \| Q_i^{(b)} | J), \quad (6)$$

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda_r \mathcal{L}_{\text{route}} + \lambda_m \mathcal{L}_{\text{mass}} + \lambda_c \mathcal{L}_{\text{causal}}. \quad (7)$$

Trọng số hàng mặc định là $w_i = 1$. Biến thể CSRD-A dùng $w_i = 1 + \beta \mathbb{E}[s_i \text{ là câu neo}]$, với nhãn loại câu gán theo Phụ lục B. Siêu tham số: $\lambda_r \in \{0.1, 0.3, 1\}$ (chọn trên tập dev), $\lambda_m = 0.1\lambda_r$, $\lambda_c = \lambda_r$. Trong 10% số bước đầu $\lambda_r = 0$, sau đó tăng tuyến tính tới giá trị đích trong 10% số bước tiếp theo.

4.6 Phân tích gradient

Bổ đề 1 (Gradient của loss định tuyến theo truy vấn). *Xét một head và một token truy vấn t thuộc bước i , với $A_{t,\cdot} = \text{softmax}(e_{t,\cdot})$. Đặt $m_j = \sum_{u \in \mathcal{I}(v_j)} A_{tu}$, $Z = \sum_{j \in \mathcal{F}(i)} m_j$, $\tilde{R}_j = m_j/Z$, và $\ell = \text{KL}(P \| \tilde{R})$ với P là một phân phối trên $\mathcal{F}(i)$. Khi đó*

- (i) $\partial\ell/\partial e_{tu} = A_{tu}(1/Z - P_j/m_j)$ nếu $u \in \mathcal{I}(v_j)$ với $j \in \mathcal{F}(i)$, và $\partial\ell/\partial e_{tu} = 0$ nếu u thuộc một nút ngoài $\mathcal{F}(i)$;
- (ii) $\sum_{u \in \mathcal{I}(v_j)} \partial\ell/\partial e_{tu} = \tilde{R}_j - P_j$ với mọi $j \in \mathcal{F}(i)$.

Chứng minh. Vì $\sum_k P_k = 1$, ta có $\ell = \text{const} - \sum_{k \in \mathcal{F}(i)} P_k \log m_k + \log Z$. Suy ra $g_k := \partial\ell/\partial m_k = 1/Z - P_k/m_k$ với $k \in \mathcal{F}(i)$, và $g_k = 0$ với các nút khác. Đạo hàm softmax cho $\partial m_k/\partial e_{tu} = A_{tu}(\mathbb{1}[u \in \mathcal{I}(v_k)] - m_k)$. Do đó $\partial\ell/\partial e_{tu} = A_{tu}(g_{k(u)} - \sum_k g_k m_k)$, trong đó $k(u)$ là nút chứa u . Mặt khác $\sum_{k \in \mathcal{F}(i)} g_k m_k = \sum_{k \in \mathcal{F}(i)} (m_k/Z - P_k) = 0$, nên (i) đúng. Lấy tổng (i) trên $u \in \mathcal{I}(v_j)$ được $m_j g_j = \tilde{R}_j - P_j$, tức (ii). $\square$

Nhận xét 1 (Ý nghĩa và phạm vi). (a) Bổ đề là dạng “ $p - y$ ” quen thuộc của softmax–cross-entropy, áp dụng cho một phân phối gộp theo nhóm khóa. Nó *không* phải kết quả toán học mới. Giá trị của nó nằm ở phép đối chiếu với (1): dưới giả định CoT-Markov, kỳ vọng độ lớn gradient CE suy giảm hình học theo khoảng cách (Zhou et al., 2026), còn tổng tín hiệu của $\mathcal{L}_{\text{route}}$ lên các logit trở tới bước j bằng đúng độ lệch $\tilde{R}_j - P_j$. Tín hiệu này không suy giảm khi student gán rất ít attention cho bước j , vì hệ số $1/m_j$ bù lại cho A_{tu} nhỏ.

- (b) “Không phụ thuộc khoảng cách” chỉ đúng *trong không gian logit*. Gradient lên W_Q, W_K còn đi qua q_t, k_u và mã hóa vị trí (RoPE).
- (c) Gradient bằng 0 tại các khóa ngoài $\mathcal{F}(i)$. Do đó $\mathcal{L}_{\text{route}}$ chỉ *phân phối lại* khối lượng *bên trong* tập đích xa, không chuyển khối lượng từ gần sang xa. $\Rightarrow$ Số hạng $\mathcal{L}_{\text{mass}}$ là **bắt buộc**. Ablation A7 với $\lambda_m = 0$ được dự đoán sẽ kém hơn.
- (d) Với trung bình trên nhiều truy vấn và head, (4) dùng phân phối gộp $Q_i^{(b)}$. Biểu thức CSRD-PQ dùng $\mathbb{E}_{t,h} \text{KL}(P_i \| \tilde{R}_t^{(l,h)})$. Biểu thức này thỏa Bổ đề chính xác cho từng số hạng, và vì $\text{KL}(P \| \cdot)$ lồi theo đối số thứ hai, nó là cận trên của (4) (A14).

4.7 Tham số hóa bằng LoRA

Mặc định. Dùng một bộ LoRA (Hu et al., 2022) trên *mọi* lớp tuyến tính ($q, k, v, o, \text{gate}, \text{up}, \text{down}$), vì LoRA chỉ trên attention kém hơn (Schulman and Thinking Machines Lab, 2025). Rank $r = 64$, $\alpha = 64$. Learning rate được quét trong $\{5 \times 10^{-5}, 10^{-4}, 2 \times 10^{-4}\}$. Hai giá trị lớn tương ứng mức khoảng $10 \times$ full FT được khuyến nghị (Schulman and Thinking Machines Lab, 2025; Li et al., 2025a); giá trị 5×10^{-5} là cấu hình LoRA của P-ALIGN (Liu et al., 2026). Batch toàn cục 16. Các loss $\mathcal{L}_{\text{CE}}, \mathcal{L}_{\text{route}}, \mathcal{L}_{\text{mass}}$ cùng cập nhật adapter này.

CSRD-QK: tách riêng tham số định tuyến. Attention ở tầng l phụ thuộc hidden state của mọi tầng bên dưới. Vì thế, nếu dùng chung adapter, gradient định tuyến sẽ đi cả vào MLP và V của các tầng thấp. Để tách riêng, ta dùng hai adapter:

- $\mathcal{A}_{\text{main}}$ (all-linear) chỉ nhận gradient của $\mathcal{L}_{\text{CE}}$;
- $\mathcal{A}_{\text{QK}}$ (rank $r_{\text{QK}} \in \{8, 32, 128\}$), đặt trên q_proj/k_proj của các tầng được chọn, chỉ nhận gradient của các loss định tuyến.

Khi tính loss định tuyến, hidden state đầu vào của q_proj/k_proj được *detach*. Việc cô lập gradient được thực hiện bằng hai lượt backward với mặt nạ theo nhóm tham số.

Dung lượng hạng thấp. Với head h , thay đổi của ma trận song tuyến $M_h = W_Q^h W_K^{h\top}$ dưới LoRA là

$$\Delta M_h = W_Q \Delta W_K^\top + \Delta W_Q (W_K + \Delta W_K)^\top,$$

nên $\text{rank}(\Delta M_h) \leq 2r$. Mục tiêu dịch khối lượng attention về một số ít câu neo nhiều khả năng khả thi với $r \geq 16$. Đây là suy luận, sẽ được kiểm chứng bằng quét rank (A13).

Thuật toán 1 Một bước huấn luyện CSRD (LoRA)

Đầu vào: Mẫu x với span nút; target $\{P_i^{(b)}, Z_{T,i}^{(b)}\}$ (và $\tilde{C}$ nếu $x \in \mathcal{D}_c$); student với LoRA; tập head $\mathcal{H}_S^{(b)}$; $\lambda_r, \lambda_m, \lambda_c; m; d_{\min}$

- 1: Token hóa x bằng tokenizer của student; lấy $\mathcal{I}_S(v_k)$ từ offset mapping
- 2: Forward (FlashAttention) $\rightarrow \mathcal{L}_{CE}$; hook lưu $q^{(l)}, k^{(l)}$ tại các tầng có head trong $\mathcal{H}_S^{(b)}$
- 3: **for** mỗi bước i có $|\mathcal{F}(i)| \geq 2$ **do** lấy $\mathcal{Q}_S(i)$ gồm token cuối và $m-1$ token ngẫu nhiên
- 4: **end for**
- 5: **for** mỗi band b , mỗi head $(l, h) \in \mathcal{H}_S^{(b)}$ **do**
- 6: $A \leftarrow \text{softmax}(q_Q^{(l,h)} k^{(l,h)\top} / \sqrt{d_h} + \text{mask nhân quả}) \triangleright N_q \times T$
- 7: Cộng dồn theo nút $\rightarrow m_t(j)$; tính $Z_t, \tilde{R}_t$ trên $\mathcal{F}(i)$; lấy trung bình theo truy vấn
- 8: **end for**
- 9: $Q_i^{(b)}, Z_{S,i}^{(b)} \leftarrow$ trung bình trên $\mathcal{H}_S^{(b)}$; tính $\mathcal{L}_{\text{route}}, \mathcal{L}_{\text{mass}}$ (và $\mathcal{L}_{\text{causal}}$)
- 10: Cập nhật LoRA với $\mathcal{L}$ (CSRD-QK: $\mathcal{L}_{CE} \rightarrow \mathcal{A}_{\text{main}}$; loss định tuyến $\rightarrow \mathcal{A}_{\text{QK}}$)

Xung đột gradient. Chúng tôi theo dõi $\cos(\nabla \mathcal{L}_{CE}, \nabla \mathcal{L}_{\text{route}})$ trên các tham số LoRA dùng chung. Nếu cosine âm kéo dài, chuyển sang adapter tách riêng hoặc PCGrad (Yu et al., 2020).

Mở rộng sang full fine-tuning. Vì LoRA “học ít hơn và quên ít hơn” (Biderman et al., 2024), sau khi có kết quả LoRA chúng tôi sẽ chạy full fine-tuning cho SFT và CSRD trên Qwen3-4B-Base để kiểm tra Giả thuyết 5.

4.8 Tính toán hiệu quả

Teacher (offline). FlashAttention (Dao, 2024) trả về log-sum-exp LSE_t cho mỗi truy vấn. Với các head đã chọn, ta tính $A_{tu} = \exp(q_t^\top k_u / \sqrt{d_h} - \text{LSE}_t)$ theo từng khối và cộng dồn khối lượng theo nút, không cần lưu ma trận $T \times T$. Mỗi trace chỉ lưu $P^{(b)}$ (thừa, tam giác dưới) và $Z^{(b)}$. Với $n \leq 400$, dung lượng tối đa khoảng 0.64 MB mỗi trace.

Student (lấy mẫu truy vấn). Mỗi bước lấy $m = 8$ truy vấn: token cuối của bước và 7 token ngẫu nhiên. Dùng hook để lấy q (đã áp RoPE) và k , rồi tính $\text{softmax}(qk^\top / \sqrt{d_h})$ có mask nhân quả trên toàn hàng. Kết quả là phân phối chính xác cho các truy vấn được chọn. Với student 1.7B, $T = 32k$, $n = 300$ và 32 head, chi phí cộng thêm khoảng 2×10^{12} FLOPs mỗi chuỗi, dưới 1% so với khoảng $6PT \approx 3 \times 10^{14}$ FLOPs của mô hình. Ma trận điểm $N_q \times T$ (khoảng $2.400 \times 32k$) chiếm khoảng 150 MB mỗi head ở bf16 và được tính lần lượt theo từng head. Overhead thực tế sẽ được đo (G6).

Huấn luyện ở 32k token. Riêng ma trận logits $32k \times$ khoảng 151k từ vựng đã chiếm khoảng 19 GB ở fp32, nên chúng tôi dùng cross-entropy hợp nhất theo khối (fused linear cross-entropy của Liger Kernel (Hsu et al., 2024)), gradient checkpointing, FlashAttention-2 và micro-batch 1.

4.9 Các biến thể

- **CSRD** (mặc định): receiver heads chọn theo excess kurtosis sau khi trừ nền; dùng $\mathcal{L}_{\text{route}} + \mathcal{L}_{\text{mass}}$; một adapter all-linear.
- **CSRD-C**: head chọn theo tương quan nhân quả, cộng $\mathcal{L}_{\text{causal}}$.
- **CSRD-A**: trọng số hàng ưu tiên câu neo.
- **CSRD-QK**: adapter Q/K riêng, hidden state được detach (kiểm định cơ chế).
- **CSRD-PQ**: KL theo từng truy vấn và từng head.

5 Giao thức chẩn đoán

Toàn bộ giao thức dùng teacher-forcing: teacher và student cùng đọc một văn bản. Vì các nút là span ký tự, P và Q tương ứng một-một theo từng hàng.

Định nghĩa 2 (Routing gap theo khoảng cách). Các bin khoảng cách (tính theo số bước) là

$$\mathcal{B} = \{[4, 8), [8, 16), [16, 32), [32, 64), [64, \infty)\}.$$

Với bin b , đặt $\mathcal{F}_b(i) = \{j \in \mathcal{F}(i) \setminus \{0\} : i - j \in b\}$. Gọi $P_i|_{\mathcal{F}_b}$ và $Q_i|_{\mathcal{F}_b}$ là các phân phối thu hẹp và chuẩn hóa lại trên $\mathcal{F}_b(i)$. Định nghĩa

$$\text{RG}(b) = \mathbb{E}_{i:|\mathcal{F}_b(i)| \geq 2} \text{JS}(P_i|_{\mathcal{F}_b} \parallel Q_i|_{\mathcal{F}_b}), \quad \Delta\mu(b) = \mathbb{E}_i \sum_{j \in \mathcal{F}_b(i)} (Q_i(j) - P_i(j)).$$

$\text{RG}(b)$ đo sự bất đồng về đích bên trong một bin. $\Delta\mu(b) < 0$ cho biết student thiếu khối lượng định tuyến ở khoảng cách b .

- D1. Hồ sơ khoảng cách:** $\text{RG}(b)$, $\Delta\mu(b)$ và độ dốc theo log khoảng cách, kèm khoảng tin cậy bootstrap theo trace. Tính trên các trace giữ lại (Mục 6.2). Phục vụ Giả thuyết 1.
- D2. Câu neo:** so sánh RG giữa câu neo và câu tính toán bằng kiểm định hoán vị có ghép cặp; đo $\text{nDCG}@k$ giữa xếp hạng vertical score của teacher và của student. Phục vụ Giả thuyết 2.
- D3. Dự báo lỗi:** trên tập dev (200 bài $\times$ 4 rollout của student), teacher teacher-force trên văn bản của student để lấy P tham chiếu. Hồi quy logistic cho nhãn “đáp án sai”, với biến kiểm soát là độ dài, NLL và số dấu hiệu phản tư; báo cáo AUC và phần AUC tăng thêm. Bổ sung so sánh gap cục bộ tại bước ngay trước lỗi đầu tiên với các bước ngẫu nhiên. Phục vụ Giả thuyết 3.
- D4. Đồng thuận attention–nhân quả:** trung vị Spearman giữa P_i và $\tilde{C}_i$, tách theo head và band.
- D5. Cơ chế tham số:** chuẩn Frobenius của cập nhật LoRA ($\Delta W = BA$) trên W_Q, W_K so với trên W_V, W_O theo từng tầng, và khoảng cách attention trung bình $\bar{d}_h = \mathbb{E}_t \sum_{u \leq t} (t - u) A_{h,t,u}$ trước và sau huấn luyện.
- D6. QK-Restore:** tắt phần LoRA trên q_proj/k_proj của student đã huấn luyện (với full FT thì khôi phục W_Q, W_K về trước huấn luyện), theo tinh thần của Zhou et al. (2026). Đo lại pass@1 và RG. Cách đọc: nếu SFT gần như không đổi sau QK-Restore còn lợi ích của CSRD giảm mạnh, thì lợi ích của CSRD có thể quy cho tham số định tuyến (Giả thuyết 4(iii)).

6 Thiết lập thực nghiệm

6.1 Mô hình

Teacher dùng để trích target phải *chính là mô hình đã sinh trace*, và phải là mô hình open-weight. Toàn bộ thực nghiệm chính dùng họ Qwen3 (Qwen Team, 2025b).

Student là các bản *Base*, vì các bản Qwen3 cỡ nhỏ đã qua hậu huấn luyện được tạo bằng quy trình chưng cất strong-to-weak từ Qwen3-32B hoặc Qwen3-235B-A22B (Qwen Team, 2025b). Nếu dùng chúng làm student, khoảng cách với teacher 8B gần như không còn, và kết quả sẽ bị lẫn với quá trình chưng cất sẵn có đó.

Vì số tầng của student 1.7B khác teacher, head được ghép theo *band độ sâu tương đối* (Mục 4.3), không cần khớp tầng một-một.

6.2 Dữ liệu

- **Huấn luyện (s1K-Q8B).** Dùng 1.000 câu hỏi của s1K (Muennighoff et al., 2025). Qwen3-8B ở chế độ thinking sinh 8 trace mỗi câu (nhiệt độ 0.6, top- p 0.95, top- k 20, tối đa 32,768 token). Chỉ giữ trace không bị cắt và có đáp án đúng:

Bảng 2: Cặp teacher–student. Cấu trúc tầng theo báo cáo kỹ thuật Qwen3 (Qwen Team, 2025b); cần đối chiếu lại với file cấu hình.

Vai trò	Teacher → Student	Mục đích
Chính	Qwen3-8B (thinking; 36 tầng) → Qwen3-1.7B-Base (28 tầng), Qwen3-4B-Base (36 tầng)	Pilot, toàn bộ ablation, bảng baseline chính; cùng tokenizer nên chạy được Token-KL
Kiểm tra quy mô teacher	Qwen3-32B (thinking) → Qwen3-4B-Base	Chỉ chạy SFT, CSRD và 1–2 baseline mạnh nhất (Giả thuyết 5)
Tùy chọn	Qwen3-8B → Llama-3.2-3B hoặc Llama-3.1-8B (Meta, 2024)	Kiểm tra tính không phụ thuộc tokenizer, nếu còn ngân sách

- câu toán được chấm bằng math-verify;
- câu có đáp án dạng tự do được chấm bằng LLM-judge so với đáp án tham chiếu.

Mỗi câu chọn ngẫu nhiên một trace đúng; bảy trace còn lại dùng làm tập ứng viên cho RSR. Nếu số câu còn lại dưới khoảng 600, bổ sung đề ở độ khó vừa từ các nguồn toán mở, có khử nhiễu.

- **Biến thể trace R1 (s1K-1.1).** Dùng nguyên trace DeepSeek-R1 của s1K-1.1 và để Qwen3-8B chỉ “đọc lại” để lấy target. Khi đó teacher không phải là mô hình viết trace. Biến thể này phục vụ hai việc: ablation A15, và đối chiếu với thiết lập của P-ALIGN (Liu et al., 2026) cùng bản cài đặt không chính thức của SGL, vì cả hai đều dùng s1K-1.1.
- **Tập dev** (200 bài) để chọn siêu tham số và chạy D3, và **tập giữ lại** (300 trace đúng của teacher) cho D1, D2 và error injection. Cả hai lấy từ các nguồn toán mở, không trùng s1K và không trùng các tập test.
- **Khử nhiễu:** kiểm tra chồng lán 13-gram giữa dữ liệu huấn luyện, tập dev và bốn tập test. AIME25 ra đời sau s1K nên được báo cáo riêng như một tập ít nguy cơ nhiễu.
- **Thống kê cần báo cáo:** tỉ lệ giữ lại, phân bố độ dài trace, số bước n và phân bố khoảng cách giữa các cặp (bước, đích).

6.3 Huấn luyện

Bảng 3: Cấu hình huấn luyện mặc định. Mọi phương pháp dùng chung dữ liệu, số token đã thấy, lịch learning rate và seeds.

Tham số	Giá trị
LoRA	all-linear (q, k, v, o, gate, up, down), $r = \alpha = 64$, dropout 0
Learning rate	quét $\{5 \times 10^{-5}, 10^{-4}, 2 \times 10^{-4}\}$; cosine, warmup 5%
Batch toàn cục / epoch	16 chuỗi; 3–5 epoch (chọn trên dev)
Độ dài tối đa	32,768 token (huấn luyện và sinh)
Hạ tầng	bf16, DeepSpeed ZeRO-3, gradient checkpointing, FlashAttention-2, fused linear cross-entropy (Hsu et al., 2024), micro-batch 1
CSRD	$d_{\min} = 4$ bước, $K_T = K_S = 16$ head mỗi band, $m = 8$, $\lambda_r \in \{0.1, 0.3, 1\}$, $\lambda_m = 0.1\lambda_r$; target nhân quả trên 20% trace (teacher 8B đủ rẻ)
Full FT (mở rộng)	Qwen3-4B-Base, lr 1×10^{-5} , cùng dữ liệu và số epoch
Seeds	3 cho mọi cấu hình trong bảng chính

Nguyên tắc công bằng.

- (i) Mọi phương pháp dùng cùng cấu hình LoRA, cùng số token đã thấy và cùng ngân sách tính chỉnh (3 giá trị learning rate và 3 giá trị cho hệ số đặc thù của mỗi phương pháp), chọn trên tập dev.
- (ii) Luôn báo cáo student trước chưng cất ([Kajitsuka et al., 2026](#)). Vì bản Base chưa quen chat template, chúng tôi báo cáo cả zero-shot và few-shot (4-shot).
- (iii) Không lấy lại số báo cáo của baseline khi thiết lập khác nhau (Mục 6.5).

6.4 Đánh giá

Benchmark. AIME 2024 (30 bài), AIME 2025 (30 bài), AMC12 và MATH500. Chúng tôi dùng đúng phiên bản AMC12 mà P-ALIGN đã dùng, để kết quả so sánh được (cần chốt trước khi chạy; xem Phụ lục E).

Chỉ số. pass@1 và pass@3, tính bằng ước lượng không chệch ([Chen et al., 2021](#)). Với mỗi bài sinh n mẫu và đếm c mẫu đúng:

$$\text{pass}@k = \mathbb{E}_{\text{bài}} \left[1 - \binom{n-c}{k} / \binom{n}{k} \right]. \quad (8)$$

Với $k = 1$, công thức này chính là accuracy trung bình trên n mẫu. Số mẫu: $n = 16$ cho AIME24, AIME25 và AMC12, vì mỗi bài AIME tương đương khoảng 3.3 điểm nên cần nhiều mẫu để giảm phương sai; $n = 4$ cho MATH500. pass@1 đo độ chính xác, pass@3 đo độ phủ. Kỳ vọng của chúng tôi là CSRD cải thiện pass@1 rõ hơn pass@3.

Cấu hình sinh. vLLM, nhiệt độ 0.6, top- p 0.95, top- k 20, tối đa 32,768 token. Đáp án được trích bằng `\boxed{}` và chấm bằng math-verify. Chúng tôi báo cáo thêm độ dài phản hồi trung bình, tỉ lệ bị cắt ở 32k và tỉ lệ không có đáp án cuối.

Thống kê. Báo cáo trung bình $\pm$ độ lệch chuẩn qua 3 seed. Khoảng tin cậy 95% tính bằng bootstrap hai tầng (bài $\times$ mẫu). So sánh với SFT dùng kiểm định hoán vị theo cặp ở mức bài, hiệu chỉnh Holm–Bonferroni khi so nhiều cấu hình.

6.5 Baseline

Bộ baseline chính tập trung vào các phương pháp Long-CoT distillation đương đại, cộng MoLSAKI là lảng giềng gần nhất về cơ chế. Tất cả đều được *tái lập* trên cùng dữ liệu (s1K-Q8B), cùng student và cùng cấu hình LoRA.

Bảng 4: Bộ baseline. “FT gốc”: chế độ fine-tuning trong bài gốc.

Baseline	Nhóm / venue	Thiết lập gốc	FT gốc	Cách dùng trong đề xuất
B0. Student trước chưng cất	–	–	–	Tự đánh giá (zero-shot và 4-shot)
B1. SFT (Kim and Rush, 2016)	Sequence-level KD	–	–	Tái lập
B2. SFT + token-level KL	KD logit (Agarwal et al., 2024)	–	–	Tái lập; logit top- k của Qwen3-8B lưu offline (cùng tokenizer)
B3. Segment Selective SFT (Wang et al., 2026)	Che loss theo segment (IG); ICLR 2026	R1-Distill-Qwen-1.5B/7B, Qwen2.5-7B-Instruct, Llama-3.1-8B-Instruct; LIMO (Ye et al., 2025) (817 mẫu); 16k	Full FT	Tái lập (mã: SiyuanWangw/SegmentSelectiveSFT); cần tính IG cho khoảng 1k trace

Baseline	Nhóm / venue	Thiết lập gốc	FT gốc	Cách dùng trong đề xuất
B4. SGL (Fan et al., 2026)	Che bước theo phổ gradient; ICML 2026 (theo nguồn thứ cấp)	10K AceReason-1.1-SFT (trace R1-0528); student 4B–8B (theo nguồn thứ cấp)	Chưa rõ	Tái cài đặt; bản không chính thức (vohuutridung/SGL) dùng s1K-1.1 và LoRA $r = 16$. Ghi rõ đây là bản tái cài đặt
B5. P-ALIGN (Liu et al., 2026)	Căn chỉnh prefix; ACL 2026	DeepSeek-R1 (s1K-1.1) → Qwen2.5-7B-Instruct, Qwen3-8B; AIME24/25, AMC12, MATH500	LoRA	Tái lập (mã: NEUIR/P-ALIGN); chạy thêm trên biến thể trace R1 để đối chiếu với bảng gốc
B6. RSR (Yang et al., 2026)	Chọn trajectory; ACL 2026	11 teacher × 5 student	Chưa rõ	Tái lập (mã: UmeanNever/RankSurprisalRatio); chọn trong 8 trace ứng viên mỗi câu; thêm hàng “RSR + CSRD”
B7. MoLSAKI (Chen et al., 2025)	KD attention bước→token số; EMNLP 2025	Llama3-8B→GPT-2 Large, Qwen2.5-32B→TinyLlama-1.1B; CoT ngắn	Chưa rõ	Cài lại cho Long-CoT, dùng chung pipeline trích attention của CSRD; chưa tìm thấy mã
Tham chiếu: Qwen3-1.7B/4B (bản hậu huấn luyện, thinking) (Qwen Team, 2025b)	Chứng cất strong-to-weak	Teacher Qwen3-32B/235B-A22B	–	Chỉ làm mốc tham chiếu, không so sánh trực tiếp

Baseline bổ sung (phụ lục): Mix Distillation (Li et al., 2025b), huấn luyện với số bước cập nhật đã căn chỉnh; FitNets/TinyBERT (Romero et al., 2015; Jiao et al., 2020); attention KD token-level kiểu MiniLM (Wang et al., 2021); RKD/CKA trên vector bước (quan hệ *đối xứng*, là ý tưởng ban đầu của nhóm) (Park et al., 2019; Kornblith et al., 2019); ULD/DSKD nếu chạy cặp khác tokenizer (Boizard et al., 2025; Zhang et al., 2024).

6.6 Ablation

Bảng 5 liệt kê 15 nhóm ablation, mỗi nhóm nhắm vào một lựa chọn thiết kế hoặc một giả định cơ chế. Mặc định chạy trên Qwen3-1.7B-Base; các cấu hình quan trọng được lặp lại trên 4B.

6.7 Phân tích hành vi và cơ chế

- **Error injection theo khoảng cách** (Phụ lục C): trên tập giữ lại, sửa sai một kết quả trung gian ở bước j mà về sau được dùng lại ở bước $i \geq j + d$, với $d \in \{4, 16, 64\}$. Đo tỉ lệ student phát hiện và sửa lỗi, kèm nhóm đối chứng.
- **Anchor deletion**: xóa một câu neo khỏi prefix và so độ nhảy của student với độ nhảy của teacher.
- **Phản tư có tác dụng**: phân loại các đoạn phản tư thành xác nhận và sửa đổi, theo tinh thần của Kang et al. (2025).
- **Phân bố tính toán theo độ khó**: tương quan giữa độ dài phản hồi và độ khó bài, với độ khó đo bằng tỉ lệ giải của teacher. Chỉ số này lấy cảm hứng từ Hu et al. (2026).
- **QK-Restore** (D6) cho SFT, CSRD và CSRD-QK; theo dõi cosine giữa gradient CE và gradient định tuyến.
- **Hiệu quả**: throughput, bộ nhớ đỉnh ở 32k, và thời gian tiền xử lý của mỗi phương pháp (IG, SVD, tìm prefix, trích target).

Bảng 5: Các nhóm ablation.

ID	Yếu tố	Các mức
A1	Ngưỡng tập đích xa	$d_{\min} \in \{1, 2, 4, 8\}$
A2	Điểm receiver (teacher)	kurtosis thô / excess kurtosis trừ nền / toàn band / K head ngẫu nhiên / theo nhân quả
A3	Loại target	attention / nhân quả / kết hợp
A4	Band độ sâu	$\mathcal{B}_1 / \mathcal{B}_2$ / cả hai
A5	Tập head student	cố định theo điểm receiver / toàn band / học được
A6	Lấy mẫu truy vấn	$m \in \{1, 4, 8, 16, \text{tất cả}\}$
A7	Hệ số	$\lambda_r \in \{0.1, 0.3, 1, 3\}$; $\lambda_m \in \{0, 0.1\lambda_r\}$ (dự đoán $\lambda_m = 0$ kém hơn)
A8	Trọng số hàng	đồng đều / ưu tiên câu neo (CSRD-A)
A9	Đơn vị phân đoạn	câu / $\backslash n \backslash n$ / episode theo từ khóa / chunk 3 bước
A10	Loại quan hệ	định tuyến <i>có hướng</i> (CSRD) so với tương đồng <i>đối xứng</i> (RKD/CKA)
A11	Kết hợp	CSRD + RSR; CSRD + Segment Selective SFT
A12	Adapter	dùng chung / CSRD-QK (adapter Q/K riêng, detach)
A13	Rank LoRA	$r \in \{16, 64, 128\}$; $r_{\text{QK}} \in \{8, 32, 128\}$
A14	Dạng loss	phân phối gộp / theo truy vấn và head (CSRD-PQ)
A15	Nguồn trace	Qwen3-8B tự sinh (teacher là tác giả) / trace R1 của s1K-1.1 (teacher chỉ đọc lại)

7 Pilot và tiêu chí go/no-go

Pilot kéo dài 2 tuần trên một node $8 \times \text{H100}$, dùng Qwen3-8B $\rightarrow$ Qwen3-1.7B-Base, dữ liệu s1K-Q8B và LoRA $r = 64$.

Cây quyết định

- **G1 $\wedge$ G3 $\wedge$ G5:** triển khai chương trình đầy đủ.
- **G1 đúng, G4 sai:** chuyển mặc định sang CSRD-C (head và target theo nhân quả), rồi chạy lại tuần 2.
- **G1 đúng, G3 và G5 sai:** chuyển sang hướng dự phòng A (Mục 11.2); giữ phần chẩn đoán làm phân tích.
- **G1 sai:** dừng CSRD và chuyển sang hướng dự phòng B (bài phân tích). Khi đó ta có một kết quả âm tính có giá trị: gradient-locality không chuyển thành routing gap ở Transformer thuần softmax.

8 Rủi ro và giảm thiểu

Bảng 7: Ma trận rủi ro.

#	Rủi ro	Mức	Giảm thiểu
R1	Routing gap không tăng theo khoảng cách ở Transformer thuần softmax	Cao	Pilot G1; cây quyết định; hướng dự phòng B
R2	Attention không phản ánh nhân quả	Cao	Target nhân quả trên 20% trace, CSRD-C, chỉ số D4
R3	Lợi ích không đến từ định tuyến (QK-Restore không làm thay đổi kết quả)	Trung bình	D6, CSRD-QK; nếu đúng như vậy thì báo cáo trung thực và điều chỉnh claim

#	Rủi ro	Mức	Giảm thiểu
R4	Dữ liệu nhỏ (khoảng 1k trace), AIME chỉ có 30 bài nên phương sai lớn	Trung bình	$n = 16$ mẫu mỗi bài, 3 seed, bootstrap hai tầng; bổ sung error injection làm chỉ số nhảy hơn
R5	Qwen3-8B giải được ít câu s1K, dữ liệu sau lọc bị thiên về câu dễ	Trung bình	Tiêu chí G0; sinh 8 trace mỗi câu; báo cáo phân bố độ khó; bổ sung đề nếu cần
R6	Teacher 8B tự nó là mô hình đã được chứng cất; reviewer nghi ngờ khả năng mở rộng	Trung bình	Lướt kiểm tra với teacher Qwen3-32B $\rightarrow$ 4B-Base
R7	LoRA hạn chế khả năng thay đổi định tuyến	Trung bình	Quét rank (A13); mở rộng sang full FT trên 4B
R8	Không vượt được Segment Selective SFT, SGL hoặc P-ALIGN	Trung bình	Chứng minh tính trực giao (A11); định vị theo cơ chế và đánh giá hành vi
R9	Bản tái cài đặt SGL không trung thành với bài gốc	Trung bình	Ghi rõ là bản tái cài đặt; công bố mã; liên hệ tác giả
R10	Bị công trình khác đi trước	Trung bình	Quét định kỳ các bài trích dẫn Bogdan et al. (2025) ; Chen et al. (2025) ; Hiding in Plain Sight (2026)
R11	Nhiệm dữ liệu giữa s1K và tập test	Thấp	Kiểm tra 13-gram; báo cáo riêng AIME25

9 Ngân sách tính toán

Đây là ước lượng thô, tính bằng node-giờ trên một node $8 \times H100$ 80GB. Điểm neo: một lượt full SFT mô hình 7B trên LIMO (817 mẫu, 16k token, 10 epoch) mất khoảng 8 GPU-giờ ([Wang et al., 2026](#)). Chúng tôi giả định thời gian tỉ lệ theo số token đã thấy, cộng thêm chi phí attention ở 32k. Teacher 8B và student $\leq 4B$ làm chi phí giảm mạnh so với các thiết lập dùng teacher 32B. Phần lớn ngân sách nằm ở khâu đánh giá: mỗi checkpoint sinh khoảng 3.600 lời giải, mỗi lời giải dài tới 32k token.

10 Kế hoạch thời gian

11 Kết quả kỳ vọng, hướng dự phòng và hạn chế

11.1 Kết quả kỳ vọng

Nếu các giả thuyết được xác nhận, kết quả sẽ là một bài báo dạng “Diagnose-then-Distill” gồm ba phần:

- (i) Routing gap tăng theo khoảng cách, tập trung ở câu neo và dự báo lỗi.
- (ii) CSRD cải thiện pass@1 và tỉ lệ phát hiện lỗi so với các phương pháp Long-CoT distillation đương đại trên AIME24, AIME25, AMC12 và MATH500, đồng thời bổ sung được cho các phương pháp tăng dữ liệu và che loss.
- (iii) QK-Restore và CSRD-QK cho thấy lợi ích gần với tham số định tuyến.

Sản phẩm công bố gồm mã nguồn (phân đoạn, trích target, loss, chẩn đoán), bộ dữ liệu s1K-Q8B kèm target đã trích, bộ error injection và các adapter LoRA.

11.2 Hướng dự phòng

A. Chứng cất có ý thức về các bước quản lý bất định. Self-distillation có thể làm năng lực lập luận giảm tới 40% khi các biểu đạt bất định (epistemic verbalization) bị triệt tiêu ([Kim et al., 2026](#)). Hướng này dùng lại hạ tầng của CSRD-A.

Bảng 6: Kế hoạch pilot và tiêu chí định lượng.

Thời gian	Công việc	Tiêu chí
Tuần 1 (dữ liệu và chẩn đoán)	- Sinh s1K-Q8B và đo tỉ lệ giữ lại. - Xác nhận receiver heads ở Qwen3-8B bằng cả hai điểm receiver. - SFT student 1.7B bằng LoRA. - Tính D1, D2 trên tập giữ lại; D3 trên tập dev; D4 trên 20 trace; chạy D6 cho student SFT.	G0: giữ lại ≥ 600 câu có trace đúng (nếu không đạt thì bổ sung đề). G1: $RG(\geq 64)/RG([4, 8]) \geq 1.5$ (khoảng tin cậy không chứa 1), hoặc $\Delta\mu(\geq 32) < 0$ có ý nghĩa. G2: gap ở câu neo cao hơn câu tính toán ($p < 0.05$). G3: AUC tăng thêm ≥ 0.03, hoặc gap cục bộ trước lỗi cao hơn các bước ngẫu nhiên. G4: trung vị Spearman attention–nhân quả ≥ 0.3.
Tuần 2 (can thiệp)	- So sánh SFT với CSRD, 3 seeds, $\lambda_r \in \{0.3, 1\}$, cùng cấu hình LoRA. - Đánh giá nhanh trên AIME24/25, AMC12 ($n = 8$) và MATH500 ($n = 4$), đo pass@1 và pass@3. - Error injection trên 100 mẫu; đo overhead tính toán ở 32k.	G5: pass@1 trung bình tăng ≥ 1.5 điểm, hoặc tỉ lệ phát hiện lỗi tăng ≥ 5 điểm mà pass@1 không giảm. G6: overhead throughput $\leq 25\%$.

B. Bài phân tích rủi ro thấp. “Student Long-CoT không thừa hưởng được gì?”: đo routing gap, sự hình thành receiver heads (Park et al., 2025), QK drift (Zhou et al., 2026) và tỉ lệ phản tư có tác dụng.

11.3 Hạn chế

- Đánh giá chỉ trên bốn benchmark toán. Khả năng tổng quát hóa sang miền khác (khoa học, lập trình) chưa được kiểm tra trong thiết lập chính.
- Dữ liệu huấn luyện nhỏ (khoảng 1k trace). Kết luận cho chế độ nhiều dữ liệu cần thực nghiệm bổ sung.
- Thực nghiệm chính dùng teacher và student cùng tokenizer. Tính không phụ thuộc tokenizer mới chỉ được kiểm tra ở cặp tùy chọn.
- Teacher chính (8B) là một mô hình đã được chưng cất. Khả năng mở rộng chỉ được kiểm tra hạn chế với teacher 32B.
- Target lấy khi teacher-forcing trên trace của teacher (off-policy). Phân đoạn dựa trên heuristic.
- Bổ đề 1 là kết quả về tín hiệu gradient, không bảo đảm accuracy tăng.

11.4 Đạo đức và giấy phép

Nghiên cứu chỉ dùng mô hình open-weight (họ Qwen3) và dữ liệu công khai (s1K), không có đối tượng người tham gia. Giấy phép của mô hình và dữ liệu sẽ được kiểm tra; adapter và dữ liệu phái sinh được phát hành theo đúng điều khoản.

Tài liệu tham khảo

R. Agarwal, N. Vieillard, Y. Zhou, P. Stańczyk, S. Ramos, M. Geist, O. Bachem. On-policy distillation of language models: Learning from self-generated mistakes. *ICLR*, 2024.

Bảng 8: Ước lượng ngân sách tính toán (hiệu chỉnh sau pilot).

Hạng mục	Node-giờ
Sinh trace: Qwen3-8B cho s1K-Q8B (8 trace mỗi câu); Qwen3-32B cho lượt kiểm tra quy mô	~15
Trích target định tuyến và target nhân quả (20% trace)	~5
Tiền xử lý riêng cho baseline (IG, SVD, tìm prefix, chấm điểm RSR)	~10
Pilot	~15
Tinh chỉnh siêu tham số trên dev (1.7B)	~15
Bảng chính: khoảng 11 cấu hình $\times$ 2 student $\times$ 3 seed	~50
Ablation (khoảng 40 lượt trên 1.7B)	~20
Biến thể trace R1, kiểm tra quy mô teacher 32B, full FT trên 4B	~25
Đánh giá (khoảng 170 checkpoint $\times$ khoảng 0.5 node-giờ)	~85
Phân tích hành vi và cơ chế	~15
Tổng	~ 255 ($\approx$11 node-ngày)

Bảng 9: Lịch triển khai, tính theo tuần từ khi bắt đầu. Hạn nộp ICML 2027 dự kiến vào cuối tháng 01/2027 và cần xác nhận trên trang chính thức.

Giai đoạn	Tuần	Công việc và mốc
T1	1–2	Pilot (Bảng 6). M1: quyết định go/no-go.
T2	3–4	Cài đặt B2–B7 dưới cấu hình LoRA chung; tiền xử lý baseline; khung đánh giá pass@k; tinh chỉnh trên dev
T3	5–8	Bảng chính trên 1.7B và 4B (3 seed); ablation A1–A8. M2: bảng kết quả chính.
T4	9–11	Ablation A9–A15; biến thể trace R1; kiểm tra quy mô teacher 32B; full FT trên 4B; phân tích hành vi và QK-Restore
T5	12–15	Viết bài; quét lại công trình liên quan; nộp ICML 2027. M3: nộp bài.
Dự phòng	–	ACL 2027 qua ARR (kiểm tra lịch chu kỳ)

- D. Biderman, J. Portes, J. J. G. Ortiz, M. Paul, P. Greengard, C. Jennings, D. King, S. Havens, V. Chiley, J. Frankle, C. Blakeney, J. P. Cunningham. LoRA learns less and forgets less. *TMLR*, 2024.
- P. C. Bogdan, U. Macar, N. Nanda, A. Conmy. Thought anchors: Which LLM reasoning steps matter? arXiv:2506.19143, 2025. Mechanistic Interpretability Workshop @ NeurIPS 2025 (spotlight).
- N. Boizard, K. El Haddad, C. Hudelot, P. Colombo. Towards cross-tokenizer distillation: The universal logit distillation loss for LLMs. *TMLR*, 2025.
- Y. Chen, J. Sheng, W. Zhang, T. Liu. Improving reasoning capabilities in small models through mixture-of-layers distillation with stepwise attention on key information. *EMNLP*, 2025. arXiv:2604.15701.
- M. Chen, J. Tworek, H. Jun, Q. Yuan, H. P. de Oliveira Pinto, et al. Evaluating large language models trained on code. arXiv:2107.03374, 2021.
- Distilling long-CoT reasoning through collaborative step-wise multi-teacher decoding. arXiv:2605.02290, 2026.
- T. Dao. FlashAttention-2: Faster attention with better parallelism and work partitioning. *ICLR*, 2024.
- DeepSeek-AI. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning. arXiv:2501.12948, 2025.
- S. Fan, et al. Uncovering the gradient geometry of long CoT: A spectral-guided approach to reasoning distillation. *ICML*, 2026 (theo nguồn thứ cấp). OpenReview: RXSg2U6R1G.
- Finding the evidence: Discovering decision-supporting tokens for on-policy reasoning distillation. arXiv:2606.22830, 2026.
- Y. Gu, L. Dong, F. Wei, M. Huang. MiniLLM: Knowledge distillation of large language models. *ICLR*, 2024.
- Hiding in plain sight: Detectability-aware antidistillation of reasoning models. arXiv:2604.23238, 2026.
- G. Hinton, O. Vinyals, J. Dean. Distilling the knowledge in a neural network. arXiv:1503.02531, 2015.

- P.-L. Hsu, et al. Liger kernel: Efficient Triton kernels for LLM training. arXiv:2410.10989, 2024.
- E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen. LoRA: Low-rank adaptation of large language models. *ICLR*, 2022.
- Y. Hu, X. Peng, S. Peng, H. Wang, T. Wang. Han Dan Xue Bu (mimicry) or Qing Chu Yu Lan (mastery)? A cognitive perspective on reasoning distillation in large language models. arXiv:2601.05019, 2026.
- S. Jain, B. C. Wallace. Attention is not explanation. *NAACL*, 2019.
- K. Ji, et al. The first few tokens are all you need: An efficient and effective unsupervised prefix fine-tuning method for reasoning models. Preprint, 2025.
- X. Jiao, Y. Yin, L. Shang, X. Jiang, X. Chen, L. Li, F. Wang, Q. Liu. TinyBERT: Distilling BERT for natural language understanding. *Findings of EMNLP*, 2020.
- T. Kajitsuka, U. Honda, S. Takase. Revisiting the capacity gap in chain-of-thought distillation from a practical perspective. arXiv:2604.08880, 2026.
- L. Kang, Y. Deng, Y. Xiao, Z. Mo, W. S. Lee, L. Bing. First try matters: Revisiting the role of reflection in reasoning models. arXiv:2510.08308, 2025.
- Y. Kim, A. M. Rush. Sequence-level knowledge distillation. *EMNLP*, 2016.
- J. Kim, et al. Why does self-distillation (sometimes) degrade the reasoning capability of LLMs? arXiv:2603.24472, 2026.
- S. Kornblith, M. Norouzi, H. Lee, G. Hinton. Similarity of neural network representations revisited. *ICML*, 2019.
- A. Kuzina, M. Pióro, P. N. Whatmough, B. Ehteshami Bejnordi. KaVa: Latent reasoning via compressed KV-cache distillation. arXiv:2510.02312 (ICLR 2026 theo trích dẫn thứ cấp).
- LARK: Learnability-grounded trajectory selection for efficient reasoning distillation. arXiv:2605.30651, 2026.
- Understanding reasoning with thought anchors and probes. *LessWrong*, 2025. <https://www.lesswrong.com/posts/f9cnGHCiJgo5eDkSQ/understanding-reasoning-with-thought-anchors-and-probes>
- D. Li, S. Cao, T. Griggs, S. Liu, X. Mo, E. Tang, S. Hegde, K. Hakhamaneshi, S. G. Patil, M. Zaharia, J. E. Gonzalez, I. Stoica. LLMs can easily learn to reason from demonstrations: Structure, not content, is what matters! arXiv:2502.07374, 2025.
- Y. Li, X. Yue, Z. Xu, F. Jiang, L. Niu, B. Y. Lin, B. Ramasubramanian, R. Poovendran. Small models struggle to learn from strong reasoners. *Findings of ACL*, 2025.
- Z. Lin, Z. Gou, Y. Gong, X. Liu, Y. Shen, R. Xu, C. Lin, Y. Yang, J. Jiao, N. Duan, W. Chen. Not all tokens are what you need for pretraining (Rho-1). *NeurIPS*, 2024.
- Z. Liu, Z. Wu, X. Li, Y. Yan, S. Wang, Z. Chen, Y. Gu, G. Yu, M. Sun. Long-chain reasoning distillation via adaptive prefix alignment. *ACL (Long)*, 2026. arXiv:2601.10064.
- LoRi: Low-rank distillation for implicit reasoning. arXiv:2606.05315, 2026.
- R. Luo, J. Li, C. Huang, W. Lu. Through the valley: Path to effective long CoT training for small language models. *EMNLP*, 2025.
- Llama Team, AI @ Meta. The Llama 3 herd of models. arXiv:2407.21783, 2024.
- MI-Distillation: Selecting from model-interpolated instruct-reasoning data spectrum for chain-of-thought distillation. arXiv:2608.29623, 2026.
- Merge-of-thought distillation. arXiv:2509.08814, 2025.
- N. Muennighoff, Z. Yang, W. Shi, X. L. Li, L. Fei-Fei, H. Hajishirzi, L. Zettlemoyer, P. Liang, E. Candès, T. Hashimoto. s1: Simple test-time scaling. arXiv:2501.19393, 2025.
- A survey of on-policy distillation for large language models. arXiv:2604.00626, 2026.
- Y. Park, M. Jeong, J. Kang. Thinking sparks!: Emergent attention heads in reasoning models during post training. arXiv:2509.25758, 2025.
- W. Park, D. Kim, Y. Lu, M. Cho. Relational knowledge distillation. *CVPR*, 2019.
- K. C. Pham, Q. P. Dao, et al. MTA: Multi-granular trajectory alignment for large language model distillation. *ACL*, 2026. arXiv:2605.01374.
- Fast and effective on-policy distillation from reasoning prefixes. arXiv:2602.15260, 2026.
- Prefix teach, suffix fade: Local teachability collapse in strong-to-weak on-policy distillation. arXiv:2605.13643, 2026.
- Qwen Team. QwQ-32B: Embracing the power of reinforcement learning. Blog, 2025.
- Qwen Team. Qwen3 technical report. arXiv:2505.09388, 2025.
- A. Romero, N. Ballas, S. E. Kahou, A. Chassang, C. Gatta, Y. Bengio. FitNets: Hints for thin deep nets. *ICLR*, 2015.
- J. Schulman, Thinking Machines Lab. LoRA without regret. *Thinking Machines Lab: Connectionism*, 2025.

doi:10.64434/tml.20250929.

- SimpleOPD: Simple tokenizer-agnostic on-policy distillation for long-context reasoning. arXiv:2608.14277, 2026.
- Skip-Thinking: Chunk-wise chain-of-thought distillation. arXiv:2505.18642, 2025.
- Curriculum learning for efficient chain-of-thought distillation via structure-aware masking and GRPO. arXiv:2602.17686, 2026.
- How to fine-tune a reasoning model? A teacher–student cooperation framework to synthesize student-consistent SFT data. arXiv:2604.14164, 2026 (ICML 2026 theo repo).
- W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, M. Zhou. MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. *NeurIPS*, 2020.
- W. Wang, H. Bao, S. Huang, L. Dong, F. Wei. MiniLMv2: Multi-head self-attention relation distillation for compressing pretrained transformers. *Findings of ACL*, 2021.
- S. Wang, Y. Liu, X. Ren. Segment-level attribution for selective learning of long reasoning traces. *ICLR*, 2026. arXiv:2602.00425.
- S. Wiegrefe, Y. Pinter. Attention is not not explanation. *EMNLP*, 2019.
- H. Xia, et al. TokenSkip: Controllable chain-of-thought compression in LLMs. arXiv:2502.12067, 2025.
- S. Yan, et al. Distribution-aligned sequence distillation for superior long-CoT reasoning. arXiv:2601.09088, 2026.
- W. Yang, X. Yue, V. Chaudhary, X. Han. Speculative thinking: Enhancing small-model reasoning with large model guidance at inference time. arXiv:2504.12329, 2025.
- Y. Yang, M. Lai, W. Zhao, X. Fan, et al. Which reasoning trajectories teach students to reason better? A simple metric of informative alignment. *ACL*, 2026. arXiv:2601.14249.
- Y. Ye, Z. Huang, Y. Xiao, E. Chern, S. Xia, P. Liu. LIMO: Less is more for reasoning. arXiv:2502.03387, 2025.
- T. Yu, S. Kumar, A. Gupta, S. Levine, K. Hausman, C. Finn. Gradient surgery for multi-task learning. *NeurIPS*, 2020.
- S. Zhang, X. Zhang, Z. Sun, Y. Chen, J. Xu. Dual-space knowledge distillation for large language models. *EMNLP*, 2024.
- X. Zhou, B. Zhu, Y. Xu, Z. Li, Y. Chen, H. Wang, Z. Guo. Attention amnesia in hybrid LLMs: When CoT fine-tuning breaks long-range recall, and how to fix it. arXiv:2606.11052, 2026.

A Bảng ký hiệu

Ký hiệu	Ý nghĩa
$v_0 = q, v_1..v_n = s_1..s_n, v_{n+1} = a$	Các nút: câu hỏi, các bước, lời giải cuối
$\mathcal{I}_M(v_k), \mathcal{Q}_M(i)$	Token của nút v_k theo mô hình M ; tập truy vấn của bước i
$m_t(j), Z_t, \tilde{R}_t$	Khối lượng attention của truy vấn t lên nút j ; khối lượng xa; phân phối chuẩn hóa
$\mathcal{F}(i), d_{\min}$	Tập đích xa; ngưỡng khoảng cách (theo bước)
$\nu_j, \hat{\nu}_j$	Vertical score; vertical score sau khi trừ nền
$\mathcal{H}_T^{(b)}, \mathcal{H}_S^{(b)}$	Tập head được chọn trong band b
$P_i^{(b)}, Q_i^{(b)}, Z_{:,i}^{(b)}$	Định tuyến target, định tuyến của student, khối lượng xa
$C[i, j], \tilde{C}_i$	Ảnh hưởng nhân quả (attention suppression) và bản chuẩn hóa
$RG(b), \Delta\mu(b)$	Routing gap và chênh lệch khối lượng trong bin b
$\mathcal{A}_{\text{main}}, \mathcal{A}_{\text{QK}}$	Adapter LoRA all-linear; adapter Q/K riêng (CSRD-QK)

B Phân đoạn và gán nhãn loại câu

- Phần suy nghĩ là văn bản giữa `<think>` và `</think>`. Phần sau `</think>` là nút a . Nút q gồm system prompt và câu hỏi.
- Tách theo `\n\n`; gộp đoạn dưới 40 ký tự; nếu $n > 400$ thì gộp cặp liền kề có tổng độ dài nhỏ nhất cho tới khi đủ.

3. Gán nhãn loại câu theo phân loại chức năng (lập kế hoạch, truy xuất sự kiện, tính toán, quản lý bất định, tự kiểm tra, tổng hợp kết quả, đưa ra đáp án), theo tinh thần của [Bogdan et al. \(2025\)](#), bằng một LLM cỡ vừa với prompt có định nghĩa và ví dụ. Kiểm tra thủ công 300 bước; báo cáo độ chính xác và Cohen's κ .
4. *Câu neo* là các bước có nhãn lập kế hoạch, quản lý bất định hoặc tự kiểm tra.

C Giao thức error injection

1. Trong trace đúng của teacher, tìm các giá trị số được gán hoặc tính ra ở bước j mà xuất hiện lại ở bước $i \geq j + d$, với $d \in \{4, 16, 64\}$.
2. Biến đổi giá trị đó theo một trong ba cách: $r \pm 1$; $r \times 10$ hoặc $r/10$; đổi dấu. Chỉ sửa ở bước j ; cắt prefix sau bước $j + 2$.
3. Student viết tiếp với nhiệt độ 0.6, 4 mẫu mỗi trường hợp, tối đa 16k token.
4. Chấm điểm theo hai tiêu chí: *phát hiện* (tính lại và nêu đúng giá trị r , kiểm tra bằng so khớp số và LLM-judge theo rubric) và *phục hồi* (đáp án cuối đúng). Báo cáo theo d và theo kiểu biến đổi.
5. Nhóm đối chứng dùng prefix không bị tiêm lỗi, để đo tỉ lệ “kiểm tra lại” nền.

D Checklist tái lập

- Công bố: mã sinh và lọc s1K-Q8B, mã phân đoạn, trích target, loss CSRD, chẩn đoán D1–D6; cấu hình LoRA; các bản cài đặt baseline; mã tính pass@ k không chệch.
- Cổ định: seeds, phiên bản thư viện (transformers, peft, vLLM, flash-attn, liger-kernel, math-verify), chat template, chế độ thinking của teacher, tham số sampling.
- Báo cáo: số token đã thấy, số bước cập nhật và ngân sách tính chính của mọi phương pháp; kết quả student trước chùng cất (zero-shot và 4-shot); tỉ lệ bị cắt ở 32k.
- Kiểm tra đơn vị:
 - so sánh khối lượng attention tính theo khối (LSE) với attention đầy đủ trên chuỗi 2k token, yêu cầu sai số $< 10^{-3}$;
 - kiểm tra gradient bằng sai phân hữu hạn;
 - kiểm tra Bổ đề 1 bằng số;
 - kiểm tra CSRD-QK thực sự chỉ cập nhật $\mathcal{A}_{QK}$ bằng các loss định tuyến;
 - kiểm tra bộ ước lượng pass@ k trên dữ liệu giả lập.

E Danh mục cần kiểm tra thủ công trước khi chạy và nộp (nội bộ)

- Phiên bản AMC12 dùng trong P-ALIGN (năm, số bài) để dùng cùng phiên bản.
- Cấu trúc tầng và head của Qwen3-1.7B, 4B, 8B theo file cấu hình; cấu hình sampling khuyến nghị cho chế độ thinking.
- Giấy phép của s1K và của họ Qwen3.
- SGL: venue, danh sách tác giả, full FT hay LoRA, và các con số báo cáo. Hiện chỉ có nguồn thứ cấp và mã không chính thức.
- Venue của Thinking Sparks và KaVa (hiện theo nguồn thứ cấp).

- Tác giả của các tài liệu đang được trích theo tên ngắn: Hiding in Plain Sight, CoRD, LARK, MI-Distillation, MoT, OPD Survey, Prefix OPD, Prefix Teach, SimpleOPD, Skip-Thinking, Structure-aware masking, Finding the Evidence, LoRi, TESSY.
- Chi tiết của MTA, UPFT, TokenSkip và Liger Kernel (tác giả, venue, arXiv ID).
- Câu trích Appendix B của [Kajitsuka et al. \(2026\)](#) về Mix Distillation.
- API trả về LSE của phiên bản flash-attn đang dùng.
- Lịch ICML 2027 và các chu kỳ ARR 2027.